

Distill Ensembles ile Çoktan Seçmeli Soru Çözümü: Çoklu Öğretmen Etiketleme ve Öğrenci Model Eğitimi

Emir Kaan SAIT
24501073
Yıldız Teknik Üniversitesi
İstanbul, Türkiye
kaan.sait@std.yildiz.edu.tr

Abstract—Bu çalışmada, çoktan seçmeli sorular için *distill ensembles* yaklaşımı incelenmiştir. Öğretmen olarak çok-adımlı akıl yürütme üretimiyle bilinen *ytu-ce-cosmos/Turkish-Gemma-9b-T1* kullanılmış ve 2000 soruluk eğitim kümesi üzerinde üç farklı öğretmen senaryosu ile etiketleme yapılmıştır. Öğretmen çıktılarındaki biçimlendirme sorunları nedeniyle yalnızca CEVAP: {A,B,C,D,E} biçiminde ayrıştırılabilen örnekler eğitime dahil edilmiştir ve bu alt-küme seçenek permütasyonu ile artırılmıştır. Öğrenci olarak *Metin/gemma-2b-tr-inst* modeli seçilmiş ve LoRA ile üç tekil öğrenci modeli eğitilmiştir. Öğretmen etiketlerine göre doğrulama doğrulukları %61–%82 aralığında gözlenirken, gold test doğrulukları yaklaşık %21 seviyesinde kalmıştır. Öğrencilerin majority voting ile birleştirilmesi test başarımını anlamlı biçimde artırmamıştır.

Index Terms—Knowledge Distillation, Ensemble Distillation, Türkçe LLM, Çoktan Seçmeli Soru Çözümü, LoRA, Quantization

I. GİRİŞ

Büyük dil modelleri (LLM) çoktan seçmeli soru çözümünde güçlü sonuçlar üretebilse de, yüksek hesaplama maliyeti ve model boyutu pratik kullanımı zorlaştırmaktadır. Bu motivasyonla bilgi damıtma, büyük bir öğretmenin bilgisini daha küçük bir öğrenciye aktararak daha düşük maliyetle benzer davranış elde etmeyi amaçlar.

Bu proje kapsamında hedef, *distill ensembles* yaklaşımını iki boyutta uygulamaktır:

- **Senaryo A (çoklu öğretmen):** Aynı sorular için farklı öğretmen çıktılarıyla birden fazla öğrenci modeli eğitmek.
- **Senaryo B (çoklu örnekleme):** Aynı öğretmenden aynı soru için birden fazla örnek çıktı alıp bunlarla öğrenci eğitmek.

Son aşamada tekil öğrenciler birleştirilerek (merge/ensemble) nihai tahmin üretilir.

Öğretmen olarak, özellikle Türkçe akıl yürütme ve planlama görevlerine uyarlanmış *Turkish-Gemma-9b-T1* seçilmiştir. Öğrenci olarak *Metin/gemma-2b-tr-inst* kullanılmıştır. Öğrencinin daha küçük bir model olması, distillation senaryosunun etkisini gözlemlemeyi kolaylaştırmaktadır.

TABLE I
KONU BAZLI EĞİTİM-TEST DAĞILIMI (TOPLAM 2500 SORU)

Konu	Toplam	Train (2000)	Test (500)
Genel Yetenek Denemeler	710	556	154
Matematik Konu Soruları	624	508	116
Biyoloji Konu Soruları	467	386	81
Vergi Uygulamaları	350	273	77
Kimya Konu Soruları	165	135	30
Geometri Konu Soruları	97	78	19
Fizik Konu Soruları	87	64	23
Toplam	2500	2000	500

II. VERİ KÜMESİ VE ÖN İŞLEME

A. Veri Kümesi Kaynağı

Çalışmada kullanılan veri kümesi *Turkish MMLU*: Yapay Zeka ve Akademik Uygulamalar İçin En Kapsamlı ve Özgün Türkçe Veri Seti v1.3’ten alınmıştır. Veri kümesi A–E seçenekli çoktan seçmeli sorulardan oluşmakta; her örnekte soru metni, seçenekler ve doğru cevap bulunmaktadır.

B. Konu Seçimi ve Gerekçesi

Öğretmen modelinin matematiksel ve mantıksal akıl yürütme odaklı hedefleri dikkate alınarak veri kümesinden **Sayısal/Mantıksal** ağırlıklı konular seçilmiştir. Bu konular, veri kümesindeki mevcut konu etiketleri kullanılarak filtrelenmiştir. Bu seçimle toplam 2500 soruluk bir çalışma havuzu oluşturulmuş; 2000 soru eğitim, 500 soru test olarak ayrılmıştır.

C. Eğitim-Test Ayrımı ve Konu Dağılımı

Ayrım, konu dağılımı korunacak biçimde uygulanmıştır. Eğitim ve test dağılımları Tablo I’da verilmektedir.

D. Şık Permütasyonu

Öğretmen etiketleme ve öğrenci eğitiminde **şık permütasyonu** kullanılmıştır. Bu adımın amacı, modelin seçenek konumunu ezberlemesini zorlaştırarak tahmini seçenek içeriğine dayandırmaktır. Her örnekte seçenekler rastgele yeniden sıralanır ve doğru şık etiketi bu sıralamaya göre yeniden haritalanır. Permütasyon öncesi ve sonrası A–E dağılımları Tablo II’te verilmiştir.

TABLE II
A–E DAĞILIMI (2000 TRAIN HAVUZU ÜZERİNDE)

Şık	Permütasyon Öncesi	Permütasyon Sonrası
A	347	406
B	392	390
C	419	436
D	434	391
E	408	377

III. YÖNTEM

A. Genel Akış

Uçtan uca süreç aşağıdaki adımlarla yürütülmüştür:

- 1) Konu odaklı filtreleme sonrası elde edilen 2500 soru, 2000 eğitim ve 500 test olarak ayrılmıştır.
- 2) Üç öğretmen senaryosu ile 2000 eğitim sorusu üzerinde etiketleme gerçekleştirilmiştir.
- 3) Öğretmen çıktılarından yalnızca CEVAP: {A, B, C, D, E} biçiminde ayrıştırılabilenler `format_ok` olarak tutulmuştur.
- 4) `format_ok` kalan örnekler $K_{perm} = 3$ ile statik permütasyon artırımı yapılarak $4 \times$ genişletilmiştir.
- 5) Her senaryo için bir öğrenci modeli LoRA ile ince ayarlanmıştır (S1, S2, S3).
- 6) Test setinde tekil öğrenciler ve majority voting ile birleştirilmiş model değerlendirilmiştir.

B. Neden Yalnızca Şık Aktarıldı?

Bu çalışmada distillation süreci, öğrenci modelin yalnızca doğru şık (A–E) tahmin etmesi üzerine kurgulanmıştır. Değerlendirme metriği ve model birleştirme (merge) aşaması da tek-harflı çıktılar üzerinden tanımlandığı için, öğretmenden öğrenciye aktarılan etiketlerin bu biçimde olması hedeflenmiştir.

Bu doğrultuda, öğretmen çıktılarından yalnızca nihai şık bilginin aktarılmasının başlıca nedenleri aşağıda özetlenmiştir:

- Öğrenci modelin eğitim hedefi yalnızca doğru şık tahmin edilmesidir. Açıklama veya serbest metin içeren çıktılar, kayıp fonksiyonunun sınıf (A–E) tahminine odaklanmasını zorlaştırarak öğrenme sinyali seyrelebilir ve modelin doğru şık yerine metin üretmeye yönelmesine neden olabilir.
- Model birleştirme (merge) aşamasında, farklı öğrenci modellerinin çıktılarından doğrudan karşılaştırılabilmesi ve majority voting uygulanabilmesi için her modelin çıktısının tek bir harf olması gerekmektedir. Değişken uzunlukta veya serbest metin içeren çıktılar, modeller arası karşılaştırmayı ve birleştirme sürecini doğrudan zorlaştırmaktadır.

Bu nedenlerle, distillation sürecinde öğretmenden öğrenciye yalnızca nihai seçenek harfi (A–E) aktarılmış; açıklama ve akıl yürütme içerikleri bilinçli olarak eğitim hedefi dışında bırakılmıştır.

C. Öğretmen Senaryoları

- **Teacher-1 (tek örnekleme / greedy):** Deterministik üretim için `do_sample=False` kullanılmış,




Fig. 1. Teacher-3 için aynı soruya ait iki örneklemin aynı şık seçme uyumu

`max_new_tokens=1024` ile uzun akıl yürütme üretilse dahi CEVAP: satırına ulaşma olasılığı artırılmıştır.

- **Teacher-2 (tek örnekleme / sampling):** `do_sample=True`, `temperature=0.7`, `top_p=0.9` ile tek çıktı alınmış; `max_new_tokens=256` seçilmiştir. Amaç, aynı öğretmenden farklı üretim modu ile etiket çeşitliliği oluşturmaktır.
- **Teacher-3 (çoklu örnekleme, $K = 2$):** Her soru için aynı öğretmenden iki çıktı üretilmiştir. Örnekleme ayarları Teacher-2 ile aynı olup `max_new_tokens=384` kullanılmıştır. Bu senaryo, aynı teacher'dan çoklu cevap üretme gereksinimini karşılar.

D. Teacher-3 Örnekleme Tutarlılığı

Teacher-3'te her soru iki kez cevaplandığı için, toplam 2000 soru üzerinde **2000 adet** (soru, cevap) çifti yerine **4000 adet** (soru, örnek) çıktısı oluşur. Bunun içinden `format_ok` olanlar filtrelendir. Şekil 1 sadece şu alt-küme üzerinde hesaplanmıştır: **aynı soruya ait iki örnek çıktının da `format_ok` olduğu ve karşılaştırılabildiği durumlar**. Bu nedenle grafikte görülen toplam sütun sayısı, “iki örneğin de geçerli olduğu soru sayısı” kadar çift içermektedir.

E. Format Filtreleme (`format_ok`)

Çıktılar regex ile CEVAP: [A–E] biçiminde ayrıştırılmıştır. `format_ok` olmayan örnekler, (i) öğrenci için hedef etiket üretilmemesi ve (ii) eğitim sinyaline gürültü eklemesi nedeniyle dışlanmıştır. Bu filtre, doğruluğu garanti etmez; yalnızca etiketin varlığını ve hedef biçime uyumunu sağlar.

F. Öğretmen Performans Özeti

Tablo III öğretmen senaryolarının `format_ok` kapsamını ve doğruluklarını özetlemektedir. Format oranlarının görece düşük olmasının temel nedeni, öğretmen modelin önce uzun

TABLE III
ÖĞRETMEN ETİKETLEME PERFORMANSI ÖZETİ

Öğretmen	Format Oranı	Doğruluk	Doğruluk (format_ok)
Teacher-1	0.37 (738/2000)	0.25 (496/2000)	0.67 (496/738)
Teacher-2	0.13 (260/2000)	0.07 (133/2000)	0.51 (133/260)
Teacher-3	0.20 (781/4000)	0.12 (490/4000)	0.63 (490/781)

bir düşünme (thinking) süreci üretmesi ve bu süreci tamamladıktan sonra çıktının en sonunda CEVAP : satırını yazabilmesidir. Bazı örneklerde düşünme süreci sonlanmadan çıktı keşildiği için açık bir cevap etiketi üretilememektedir. Bu nedenle doğruluk yalnızca format_ok olan örnekler üzerinde ölçülmüştür. Çünkü doğru cevabın değerlendirilebilmesi, model çıktısında düşünme sürecini takiben açık ve tekil bir şık bilgisinin (A–E) yer almasını gerektirmektedir. Bu gerekçeyle öğrenci modeli eğitimi yalnızca format_ok alt-kümesi kullanılarak gerçekleştirilmiştir.

G. Veri Artırma: Statik Permütasyon ($K_{perm} = 3$)

format_ok kalan her örnek için seçenekler üç ek kez permüte edilerek veri artırma uygulanmıştır. Böylece her örnek toplam $1 + K_{perm} = 4$ satıra genişlemiştir. Elde edilen büyüklükler:

- Teacher-1: 738 $\rightarrow$ 2952
- Teacher-2: 260 $\rightarrow$ 1040
- Teacher-3: 781 $\rightarrow$ 3124

Bu tercih, dinamik permütasyon yerine daha izlenebilir ve tekrar üretilebilir bir eğitim veri seti sağlamıştır.

IV. ÖĞRENCİ MODELİ VE EĞİTİM KURULUMU

A. Öğrenci Model Seçimi

Öğrenci olarak Metin/gemma-2b-tr-inst kullanılmıştır. Bu seçim, daha küçük bir modelin distillation ile ne ölçüde iyileşebileceğini incelemek için uygundur.

B. Girdi-Çıktı Biçimi

Model girdisi aşağıdaki şablonla oluşturulmuş; hedef çıktı yalnızca tek bir seçenek harfi (A–E) olacak şekilde tanımlanmıştır:

Soru:

...

- A) ...
- B) ...
- C) ...
- D) ...
- E) ...

Cevap:

Kayıp hesabında prompt tokenları maskeleyerek eğitim sinyalinin yalnızca cevap harfine odaklanması sağlanmıştır.

C. Eğitim Ayarları

Tüm öğrenci eğitimlerinde ortak ayarlar şu şekildedir:

- 4-bit quantization: NF4, double quant, bf16 hesaplama
- LoRA: $r = 16$, $\alpha = 32$, dropout 0.05
- Maksimum uzunluk: MAX_LEN=384
- Eğitim: öğrenme oranı $2 \cdot 10^{-4}$, warmup=0.03
- Batch: per-device 8, gradient accumulation 2

D. Validation Kurulumu

Validation doğruluğu (VAL ACC), öğretmen etiketlerine göre ölçülmüştür. Bunun amacı:

- 1) **Öğretmeni ne kadar öğrendiğini ölçmek:** Distillation’da ilk hedef, öğrencinin öğretmen tarafından üretilen etiket dağılımını taklit edebilmesidir.
- 2) **Aşırı uyumu (overfitting) kontrol etmek:** Eğitim verisinde ölçülen doğruluk, modelin aynı etiketleri ezberlemesini maskeleyebilir.
- 3) **Hızlı ve ucuz sinyal:** Gerçek gold test doğruluğu her zaman nihai metrik olsa da, geliştirme döngüsünde öğretmen etiketlerine göre doğrulama, “öğrenci eğitimi çalışıyor mu?” sorusuna hızlı yanıt verir.

V. DENEY SONUÇLARI

A. Eğitim Kayıp Eğrileri

Eğitim kayıp eğrileri Şekil 2–4’te verilmiştir. Kayıp değerlerinin azalma eğilimi, öğrencinin hedef tek-harf çıktıyı öğrenmeye yöneldiğini göstermektedir.

B. Öğrenci Doğrulama Sonuçları

Üç öğrencinin öğretmen etiketlerine göre doğrulama doğrulukları:

- Student-1: 0.8158
- Student-2: 0.6111
- Student-3: 0.8182

Bu değerler, öğrencilerin öğretmen etiketlerini belirli ölçüde öğrenebildiğini göstermektedir. Özellikle Student-1 ve Student-3, öğretmen etiketlerini yüksek oranda taklit etmektedir.

C. Validation İçin Şık Dağılım Analizi

Şık dağılım grafikleri, modelin belirli şıklara “çökme” (mode collapse) eğilimini ve teacher etiket dağılımına yakınlığını görmek için kullanılmıştır. Üç öğrenci için doğrulama setindeki tahmin ve gold dağılımları Şekil 5–7’te verilmiştir. Grafikler incelendiğinde, tahminlerin tek bir şık üzerinde yoğunlaşmadığı; aksine seçenekler arasında görece dengeli dağıldığı görülmektedir. Bu durum, doğrulama aşamasında belirgin bir “çökme” davranışı olmadığını ve modelin tüm şıkları kullanabildiğini göstermektedir.




Fig. 2. Student-1 eğitim kaybı (loss) eğrisi.




Fig. 4. Student-3 eğitim kaybı (loss) eğrisi.




Fig. 3. Student-2 eğitim kaybı (loss) eğrisi.

TABLE IV
TEST DOĞRULUKLARI (500 SORU, GOLD ETİKETLERE GÖRE)

Model	Test Doğruluğu
Student-1	0.212
Student-2	0.226
Student-3	0.222
Merged (S1+S2+S3)	0.214

D. Test Sonuçları

Tekil öğrenciler (S1, S2, S3) ve bu modellerin test aşamasında her soru için ürettikleri tahminlerin çoğunluk oyu (majority voting) ile birleştirilmesiyle elde edilen birleşik modelin gold test doğrulukları Tablo IV'te sunulmuştur.

Bu değerler, 5 seçenekli bir problemde rastgele taban başarımın %20 olduğu düşünüldüğünde, kazanımın sınırlı kaldığını göstermektedir. Doğulamada yüksek görünen başarımın gold testte yansımadığı görülmüştür.




Fig. 5. Student-1 doğrulama seti şık dağılımı (tahmin vs teacher).




Fig. 6. Student-2 doğrulama seti şık dağılımı (tahmin vs teacher).

E. Test Şık Dağılımı ve Birleştirme

Şekil 8, birleştirilmiş modelin test setindeki tahmin dağılımını göstermektedir. Dağılımın gold'a yakın ol-




Fig. 7. Student-3 doğrulama seti şık dağılımı (tahmin vs teacher).




Fig. 8. Test setinde birleştirilmiş model (S1+S2+S3) tahmin şık dağılımı (tahmin vs gold).

ması, düşük test doğruluğunun temel sebebinin “tek bir şıkka çökme” olmadığını; daha çok öğretmen kaynaklı etiket gürültüsünün öğrenciye taşınmasıyla ilişkili olduğunu düşündürmektedir.

VI. TARTIŞMA

A. Başarımın Sınırlı Kalmasının Nedenleri

Sonuçlar dört ana faktöre işaret etmektedir:

- **Öğretmen doğruluğu:** Öğrenci modeli doğrudan gold etiketleri(ground truth) değil, öğretmenin ürettiği etiketleri öğrenmektedir. Bu nedenle öğretmenin yaptığı sistematik hatalar distillation süreciyle öğrenci modele aktarılmaktadır.
- **Kapsama (format) sorunu:** Düşük `format_ok` oranı, eğitime giren özgün örnek sayısını azaltmaktadır (özellikle Teacher-2 senaryosunda). Bu durum öğrenci modelin temsil gücünü sınırlamaktadır.
- **Eğitim–test dağılımı farkı:** Eğitim aşamasında yalnızca `format_ok` olan, yani çıktısında açık bir CEVAP : satırı bulunan örnekler kullanılmıştır. Buna karşılık train ve test kümeleri konu dağılımı açısından dengeli olacak şekilde

ayrıldığı için, formatı uzun veya bozuk olan bazı soru tipleri test kümesinde yer almaya devam etmiştir. Bu soru türleri öğrenci model tarafından eğitim sırasında yeterince görülmediğinden, test doğruluğunu olumsuz etkilemiştir.

- **Veri artırmanın sınırı:** Permütasyon ile satır sayısı artırılmış olsa da içerik çeşitliliği aynı sorularla sınırlı kalmaktadır. Bu nedenle veri miktarındaki artış her zaman genelleme performansında artış anlamına gelmemektedir.

B. Birleştirmenin Sınırlı Katkısı

Majority voting ile birleştirme, hataların bağımsız olduğu durumda fayda sağlayabilir. Ancak bu çalışmada öğrenciler benzer öğretmen kaynaklı gürültüyü paylaştığı için hata korelasyonu yüksek kalmış ve birleştirme kazancı sınırlı olmuştur.

VII. SONUÇ

Bu çalışmada distill ensembles yaklaşımı çoktan seçmeli soru çözümüne uygulanmıştır. Öğretmen olarak Turkish-Gemma-9b-T1 kullanılarak üç senaryoda etiket üretilmiş, yalnızca `format_ok` örnekler üzerinden statik permütasyonla veri artırılmış ve `gemma-2b-tr-inst` öğrenci modeli LoRA ile ince ayarlanmıştır. Öğretmen etiketlerine göre doğrulama doğrulukları yüksek olsa da gold test doğruluğu $\sim 21\%$ seviyesinde kalmış ve birleştirme anlamlı kazanım sağlamamıştır. Bulgular, distillation başarımının öğretmen doğruluğu, `format_ok` kapsamı ve etiket gürültüsüne kritik düzeyde bağımlı olduğunu göstermektedir.

REFERENCES

- [1] Zenodo Dataset, “Turkish MMLU: Yapay Zeka ve Akademik Uygulamalar İçin En Kapsamlı ve Özgün Türkçe Veri Seti v1.3.” [Çevrimiçi]. Erişim: <https://zenodo.org/records/16283327>.
- [2] Hugging Face Model Card, “ytu-ce-cosmos/Turkish-Gemma-9b-T1.” [Çevrimiçi]. Erişim: <https://huggingface.co/ytu-ce-cosmos/Turkish-Gemma-9b-T1>.
- [3] Hugging Face Model Card, “Metin/gemma-2b-tr-inst.” [Çevrimiçi]. Erişim: <https://huggingface.co/Metin/gemma-2b-tr-inst>.
- [4] Kod deposu. [Çevrimiçi]. Erişim: <https://github.com/krlov/my-project/>.
- [5] Deneyisel çıktılar ve ek dosyalar. Google Drive klasörü. [Çevrimiçi]. Erişim: <https://drive.google.com/drive/folders/1ZCbD4MeXUwP0SvzQP89iFwshCJ0hZxXT?usp=sharing>.